此外还有非常多的节点遍历方法，详情请参见 BeautifulSoup 的官方文档。

4.2 案例1 中国大学排名爬取

4.2.1 任务描述

爬取“高三网”中国大学排名一览表，爬取数据包括学校名称、总分、全国排名、星级排名、办学层级。爬取后的数据保存在 CSV 文件中。目标网址 http://www.bspider.top/gaosan/，参考页面如 4-5 所示。

中国的大学排名一览表

名次	学校名称	总分	全国排名	星级排名	办学层次
1	北京大学	100	1	8★	世界一流大学
2	清华大学	99.81	2	8★	世界一流大学
3	浙江大学	80.72	4	8★	世界一流大学
4	复旦大学	79.75	3	8★	世界一流大学
5	南京大学	76.85	5	8★	世界一流大学
6	上海交通大学	76.09	6	8★	世界一流大学
7	武汉大学	75.75	10	7★	世界知名高水平大学
8	中国人民大学	73.75	9	8★	世界一流大学

图 4-5 中国大学排名一览表

4.2.2 任务分析

从中国好大学排名案例开始学习网页数据解析。代码编写将按照网页数据获取、网页解析以及数据存储三个步骤编写。网页数据获取采用 GET 请求通用函数 get_html，网页解析采用 BeautifulSoup 完成页面解析，数据存储将数据解析的输出保存为逗号分隔的 CSV 文件。核心的解析任务依然使用浏览器开发者工具确定 CSS 选择器，并通过二次查找的方式提取需要的数据。

首要任务是通过浏览器开发者工具分析页面布局结构。使用 Chrome 浏览器打开高三网，使用 F12 快捷键打开浏览器开发者工具，然后按住“Ctrl + Shift + C”快捷键，用鼠标选择任意一行排名信息。通过观察发现中国大学排名一览表采用 table 进行布局，页面结构如图 4-6 所示。

```
<h2>中国的大学排名一览表</h2>
▼<table border="1">
  ▼<tbody>
    ▼<tr class="firstRow">
       <td>名次</td>
       <td>学校名称</td>
       <td>总分</td>
       <td>全国排名</td>
       <td>星级排名</td>
       <td>办学层次</td>
     </tr>
    ▼<tr>
       <td>1</td>
       <td style="word-break: break-all;">北京大学</td>
       <td>100</td>
       <td>1</td>
       <td>8★</td>
       <td>世界一流大学</td>
     </tr>
```

图 4-6 中国大学排名页面结构

扫描全能王 3亿人都在用的扫描App

通过 table 标签的 class 属性控制解析数据的范围，所有的正式数据都是放到 tbody 标签下，可以使用 CSS 选择器“table>tbody>tr”一次性提取所有的数据行。确定选择器后，在“Elements”选项卡下按住“Ctrl + F”快捷键，输入 CSS 选择器进行确认，确认获取的 tr 行数是否和展示的实际行数相匹配，如图 4-7 所示。

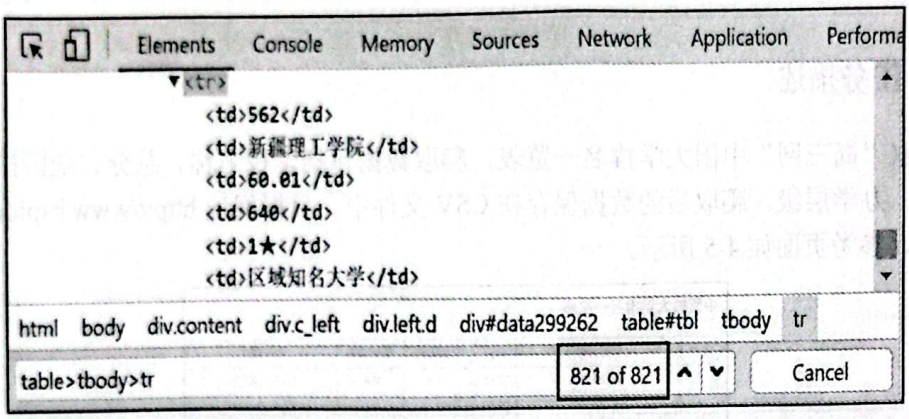


图 4-7　浏览器开发者工具验证 CSS 选择器

匹配的数据行数为 821 行，刚好和网页中的 821 所大学对应，这样就确定了外层数据行的 CSS 选择器。具体的排名数据需要循环遍历时再次进行查找，这种方式一般称之为二次查找。下面可以着手编写爬虫代码，一边调试一边确定排名信息 CSS 选择器。

4.2.3　任务实现

1. 编写初步代码

通过分析并形成基本思路后，可以初步开始编写代码。代码一般都是边写边完善，不是一次成型的，希望读者能够养成代码重构的习惯。由于网站没有反爬虫机制，GET 请求通用函数去掉了 User-Agent 以简化代码。parser 函数接收 get_html 函数的输出数据，循环输出每个 tr 的 HTML 片段。参考代码如下：

```
import  requests                    #导包
from bs4 import BeautifulSoup
def get_html(url,time=10):          #GET 请求通用函数，去掉了 User-Agent 简化代码
    try:
        r = requests.get(url, timeout=time)        #发送请求
        r.encoding = r.apparent_encoding           #设置返回内容的字符集编码
        r.raise_for_status()        #返回的状态码不等于 200 抛出异常
        return r.text               #返回网页的文本内容
    except Exception as error:
        print(error)
def parser(html):                   #解析函数
    soup=BeautifulSoup(html,"lxml")                #将获取的 HTML 转换为 soup 对象
    for row in soup.select("table>tbody>tr"):      #循环遍历获取每行数据
        print(row)
```

扫描全能王
3亿人都在用的扫描App

```
if __name__=="__main__":  #main 函数整合流程
    url="http://www.bspider.top/gaosan/"
    html=get_html(url)
    parser(html)
```

部分运行结果如下：

```
<tr class="firstRow">
<td>名次</td>
<td>学校名称</td>
<td>总分</td>
<td>全国排名</td>
<td>星级排名</td>
<td>办学层次</td>
</tr>
```

2. 编写解析函数

从排名信息片段中可以看出数据全部为 td 标签的文本，可以在行 row 的基础上再次查找 td，按照顺序获取想要的信息。为了给数据存储提供信息，可以将数据存储为列表，每行数据都为列表类型。解析函数 parser 代码如下：

```
def parser(html):
    soup=BeautifulSoup(html,"lxml")          #HTML 转换为 soup 对象
    out_list=[]                              #解析函数输出数据的列表
    for row in soup.select("table>tbody>tr"): #循环遍历 tr
        td_html=row.select("td")             #获取 td
        row_data=[
            td_html[1].text.strip(),         #学校名称
            td_html[2].text.strip(),         #总分
            td_html[3].text.strip(),         #全国排名
            td_html[4].text.strip(),         #星级
            td_html[5].text.strip()          #办学层次
                ]
        out_list.append(row_data)            #将解析的每行数据插入到输出列表中
    return out_list
```

3. 编写存储函数

CSV 文件是由逗号分隔的文本文件，每行使用换行符分隔。CSV 操作需要导入 Python 标准库 CSV，使用 import csv。save_csv 函数参考代码如下：

```
def save_csv(item,path):
    with open(path, "a+", newline='',encoding="utf-8") as f:
    csv_write = csv.writer(f)
    csv_write.writerows(item)
```

扫描全能王
3亿人都在用的扫描App

save_csv 函数的输入参数为 item 和 path，参数 item 为列表类型，参数 path 为保存在磁盘上的路径。通过 Python 的文件操作将列表写入文件。通过 with open 函数创建文件，其中参数“a+”的含义为追加模式读写文件，encoding="utf-8"的含义为设置文件编码方式为 utf-8，参数 newline 设置换行符，由于 Windows 平台和 Linux 平台的换行符不一致，需要重新设置换行符 newline=''，否则会生成空行。通过 csv_write.writerows(item)将 item 列表数据写入文件。

4. 完整代码

以上各个函数通过 main 函数进行整合。希望读者在编写爬虫过程中能够找到规律，编写自己的通用函数如 get_html、save_csv。整合后的完整代码如下：

```
import  requests
from bs4 import BeautifulSoup
import csv
def get_html(url,time=3):          #GET 请求通用函数，去掉了 User-Agent 简化代码
    try:
        r = requests.get(url, timeout=time)     #发送请求
        r.encoding = r.apparent_encoding        #设置返回内容的字符集编码
        r.raise_for_status()                    #返回的状态码不等于 200 抛出异常
        return r.text                           #返回网页的文本内容
    except Exception as error:
      print(error)
def parser(html):                               #解析函数
    soup=BeautifulSoup(html,"lxml")             #HTML 转换为 soup 对象
    out_list=[]                                 #解析函数输出数据的列表
    for row in soup.select("table>tbody>tr"):   #循环遍历 tr
        td_html=row.select("td")                #获取 td
        row_data=[
            td_html[1].text.strip(),            #学校名称
            td_html[2].text.strip(),            #总分
            td_html[3].text.strip(),            #全国排名
            td_html[4].text.strip(),            #星级
            td_html[5].text.strip()             #办学层次
        ]
        out_list.append(row_data)               #将解析的每行数据插入到输出列表中
    return out_list
def save_csv(item,path):                        #数据存储，将 list 数据写入文件
    with open(path, "w+", newline='',encoding="utf-8") as f:  #创建 utf-8 编码文件
        csv_write = csv.writer(f)               #创建写入对象
```

扫描全能王
3亿人都在用的扫描App

```
        csv_write.writerows(item)          #一次性写入多行
if __name__=="__main__":
    url="http://www.bspider.top/gaosan/"
    html=get_html(url)                     #获取网页数据
    out_list=parser(html)                  #解析网页，输出列表数据
    save_csv(out_list,"school.csv")        #数据存储
```

4.3 案例2 百度新闻爬取

4.3.1 任务描述

爬取百度新闻首页中的热点要闻，爬取数据包括新闻标题以及新闻详情页链接。爬取后的数据保存在 CSV 文件中。百度新闻的 URL 地址为 http://www.bspider.top/baidunews，参考页面如图 4-8 所示。



图 4-8 百度新闻——热点要闻

4.3.2 任务分析

通过中国大学排名案例的学习，读者已经熟悉了爬虫编写的三个步骤，分别为网页数据获取、网页解析以及数据存储。其中网页数据获取、数据存储已经分别封装为通用函数 get_html 和 save_csv。读者编写爬虫程序时只需要关注解析函数的编写即可，并通过 main 函数整合三个函数，控制数据的输入和输出。

网页解析的基本思路为使用浏览器的开发者工具确定解析表达式，然后结合 Python 标准库如正则表达式 Re 或第三方库如 BeautifulSoup、lxml 等提取网页数据。

通过分析页面结构，并结合元素选取工具发现“热点要闻”的 HTML 结构稍微有点复杂，分为热点新闻和焦点新闻两部分。其中热点新闻被 class 为“hotnews”的 div 包裹，焦点新闻被 class 为“focuslistnews”的 ul 包裹。根据页面 HTML 结构确定 CSS 选择器是分

扫描全能王 3亿人都在用的扫描App